
POS TECH

TECH CHALLENGE

Tech Challenge é o projeto da fase que englobará os conhecimentos obtidos em todas as disciplinas da fase. Esta é uma atividade que, a princípio, deve ser desenvolvida em grupo. É importante atentar-se ao prazo de entrega, pois trata-se de uma atividade obrigatória, uma vez que vale 90% da nota de todas as disciplinas da fase.

Tema Central: Observabilidade Contínua, Detecção de Drift, Qualidade de Dados e Governança em Produção

Contexto

Uma fintech de concessão de crédito possui um modelo de Credit Scoring rodando em produção. No entanto, com recentes mudanças na economia (inflação, novos perfis de clientes), a diretoria suspeita que o modelo está tomando decisões erradas e sofrendo degradação silenciosa.

O foco deste projeto é construir a camada de **Sustentação e Confiabilidade**. O grupo deverá pegar um modelo de classificação simples, criar contratos de qualidade de dados, simular um cenário de degradação ao longo do tempo (Data Drift e Concept Drift), detectar essa mudança com ferramentas de observabilidade e garantir que todo o processo esteja documentado sob as regras de governança e privacidade (LGPD), incluindo uma análise causal do problema.

Requisitos Obrigatórios

Repositório GitHub

- Pipeline de validação de dados (data contracts) configurado.
- Scripts para simulação e detecção estatística de Drift.
- Dashboards ou relatórios HTML gerados comprovando o monitoramento.
- Documentação consolidada de Governança no README.md.

- Histórico de commits semântico e organizado.

Vídeo (5 minutos — método STAR)

- **Situation:** o risco da degradação silenciosa de modelos de crédito no mundo real.
- **Task:** requisitos técnicos da fase (interceptar dados ruins, detectar drift, garantir compliance).
- **Action:** ferramentas escolhidas de validação e observabilidade, simulação do drift e plano de governança.
- **Result:** demonstração prática do relatório apontando o drift, alertas gerados e lições aprendidas.

Bibliotecas Requeridas

- **Scikit-Learn / XGBoost** — para treinar o modelo base de risco de crédito.
- **Great Expectations** ou **Pandera** — para validação e qualidade de dados (Data Contracts).
- **Evidently AI** (ou Alibi Detect) — para detecção de Data/Concept Drift e geração de relatórios.
- Opcional (se quiserem integrar com a Fase 3): Prometheus-client para métricas.

Boas Práticas Obrigatórias

- Separação clara entre o dataset de Referência (usado no treino) e o dataset de Análise/Produção (onde o drift ocorre).
- Implementação de pelo menos 3 regras rígidas de qualidade de dados (ex.: sem nulos, range de idade, limites de renda).

- Relatório estatístico evidenciando a mudança de distribuição (ex.: teste PSI ou Kolmogorov-Smirnov).
- Documentação de compliance contendo plano de privacidade (LGPD).

Etapas de Desenvolvimento (4 Etapas)

Etapa 1 — Validação de Dados e Contratos (Disciplina: Validação de Dados e Bibliotecas de Qualidade)

Foco: Garantir que lixo não entre no modelo.

Tarefas:

- Treinar um classificador base para o problema de crédito usando um dataset limpo (Dataset de Referência).
- Criar um contrato de dados (usando Great Expectations ou Pandera) estabelecendo regras estritas (ex.: idade > 18, renda não pode ser nula, sem duplicatas).
- Forçar a passagem de um lote de dados com erros para demonstrar o contrato falhando e bloqueando a ingestão.
    - **Entregável:** Script de validação de dados operante e modelo baseline treinado.

Etapa 2 — Simulação e Detecção de Drift (Disciplina: Data Drift)

Foco: Diagnosticar a degradação do modelo ao longo do tempo.

Tarefas:

- Criar um "Dataset de Produção" simulando a passagem do tempo, alterando intencionalmente a distribuição de pelo menos duas variáveis importantes (ex.: aumentar artificialmente a renda ou a taxa de desemprego dos clientes).
- Gerar predições para esse novo dataset.

- Utilizar o **Evidently AI** para comparar o Dataset de Referência com o Dataset de Produção.
- Identificar através dos testes estatísticos (PSI, Kolmogorov-Smirnov etc.) quais features sofreram Drift.
    - **Entregável:** Relatório de Drift (HTML do Evidently ou painel customizado) apontando claramente as variáveis degradadas.

Etapa 3 — Observabilidade de Pipelines e Modelos (Disciplina: Monitoramento de Pipelines e Infraestrutura)

Foco: Visibilidade operacional dos pipelines de dados, da infraestrutura e dos modelos em produção.

Tarefas:

- **Centralizar logs e métricas:** Integrar os logs de execução do pipeline (sucesso/falhas na ingestão e transformação de dados) e os resultados dos testes de Drift da Etapa 2.
- **Implementar o Rastreamento/Monitoramento:** O grupo pode optar por rastrear o ciclo de vida do modelo e experimentos utilizando o **MLflow**, ou exportar as métricas da infraestrutura e do pipeline para um dashboard interativo (utilizando **Datadog**, soluções Cloud nativas ou alternativas Open-Source).
- **Definir e Documentar Métricas:** Documentar as métricas de saúde operacionais escolhidas (ex: status de execução das tarefas do pipeline, latência, volume de dados processados, e quantidade de alertas de falha ou drift).

Entregável: Dashboard de monitoramento ou ambiente de rastreamento (ex: MLflow / Datadog) evidenciando a saúde completa do pipeline de dados, a estabilidade da infraestrutura e os alertas de degradação do modelo.

Etapa 4 — Governança (Disciplinas: Privacy By Design e By Default)

Foco: Documentação arquitetural, compliance e prescrição.

Tarefas (Teóricas, no README.md):

- **Governança e LGPD:** Escrever um plano de proteção de dados explicando como dados sensíveis (PII) foram tratados neste projeto, qual a base legal para a decisão de crédito e o plano de retenção.
- Gravar o vídeo STAR demonstrando o projeto.
- **Entregável:** Documentação completa de Governança e Causalidade no README + Link do Vídeo.

Critérios de Avaliação

Critério	Peso	Descrição
Validação de Dados	25%	Contratos de dados configurados corretamente (Great Expectations/Pandera) interceptando anomalias.
Detecção de Drift	25%	Simulação correta de alteração de distribuição e geração clara de relatório com Evidently AI.
Observabilidade e Logs	20%	Apresentação visual das métricas de saúde do modelo e dos alertas de drift (Dashboard ou Relatórios automatizados).

Governança (LGPD)	15%	Clareza na documentação sobre privacidade, base legal e mitigação de vieses.
Vídeo STAR	15%	Clareza na demonstração técnica da degradação do modelo e explicação do impacto (≤ 5 min).

Dataset Sugerido

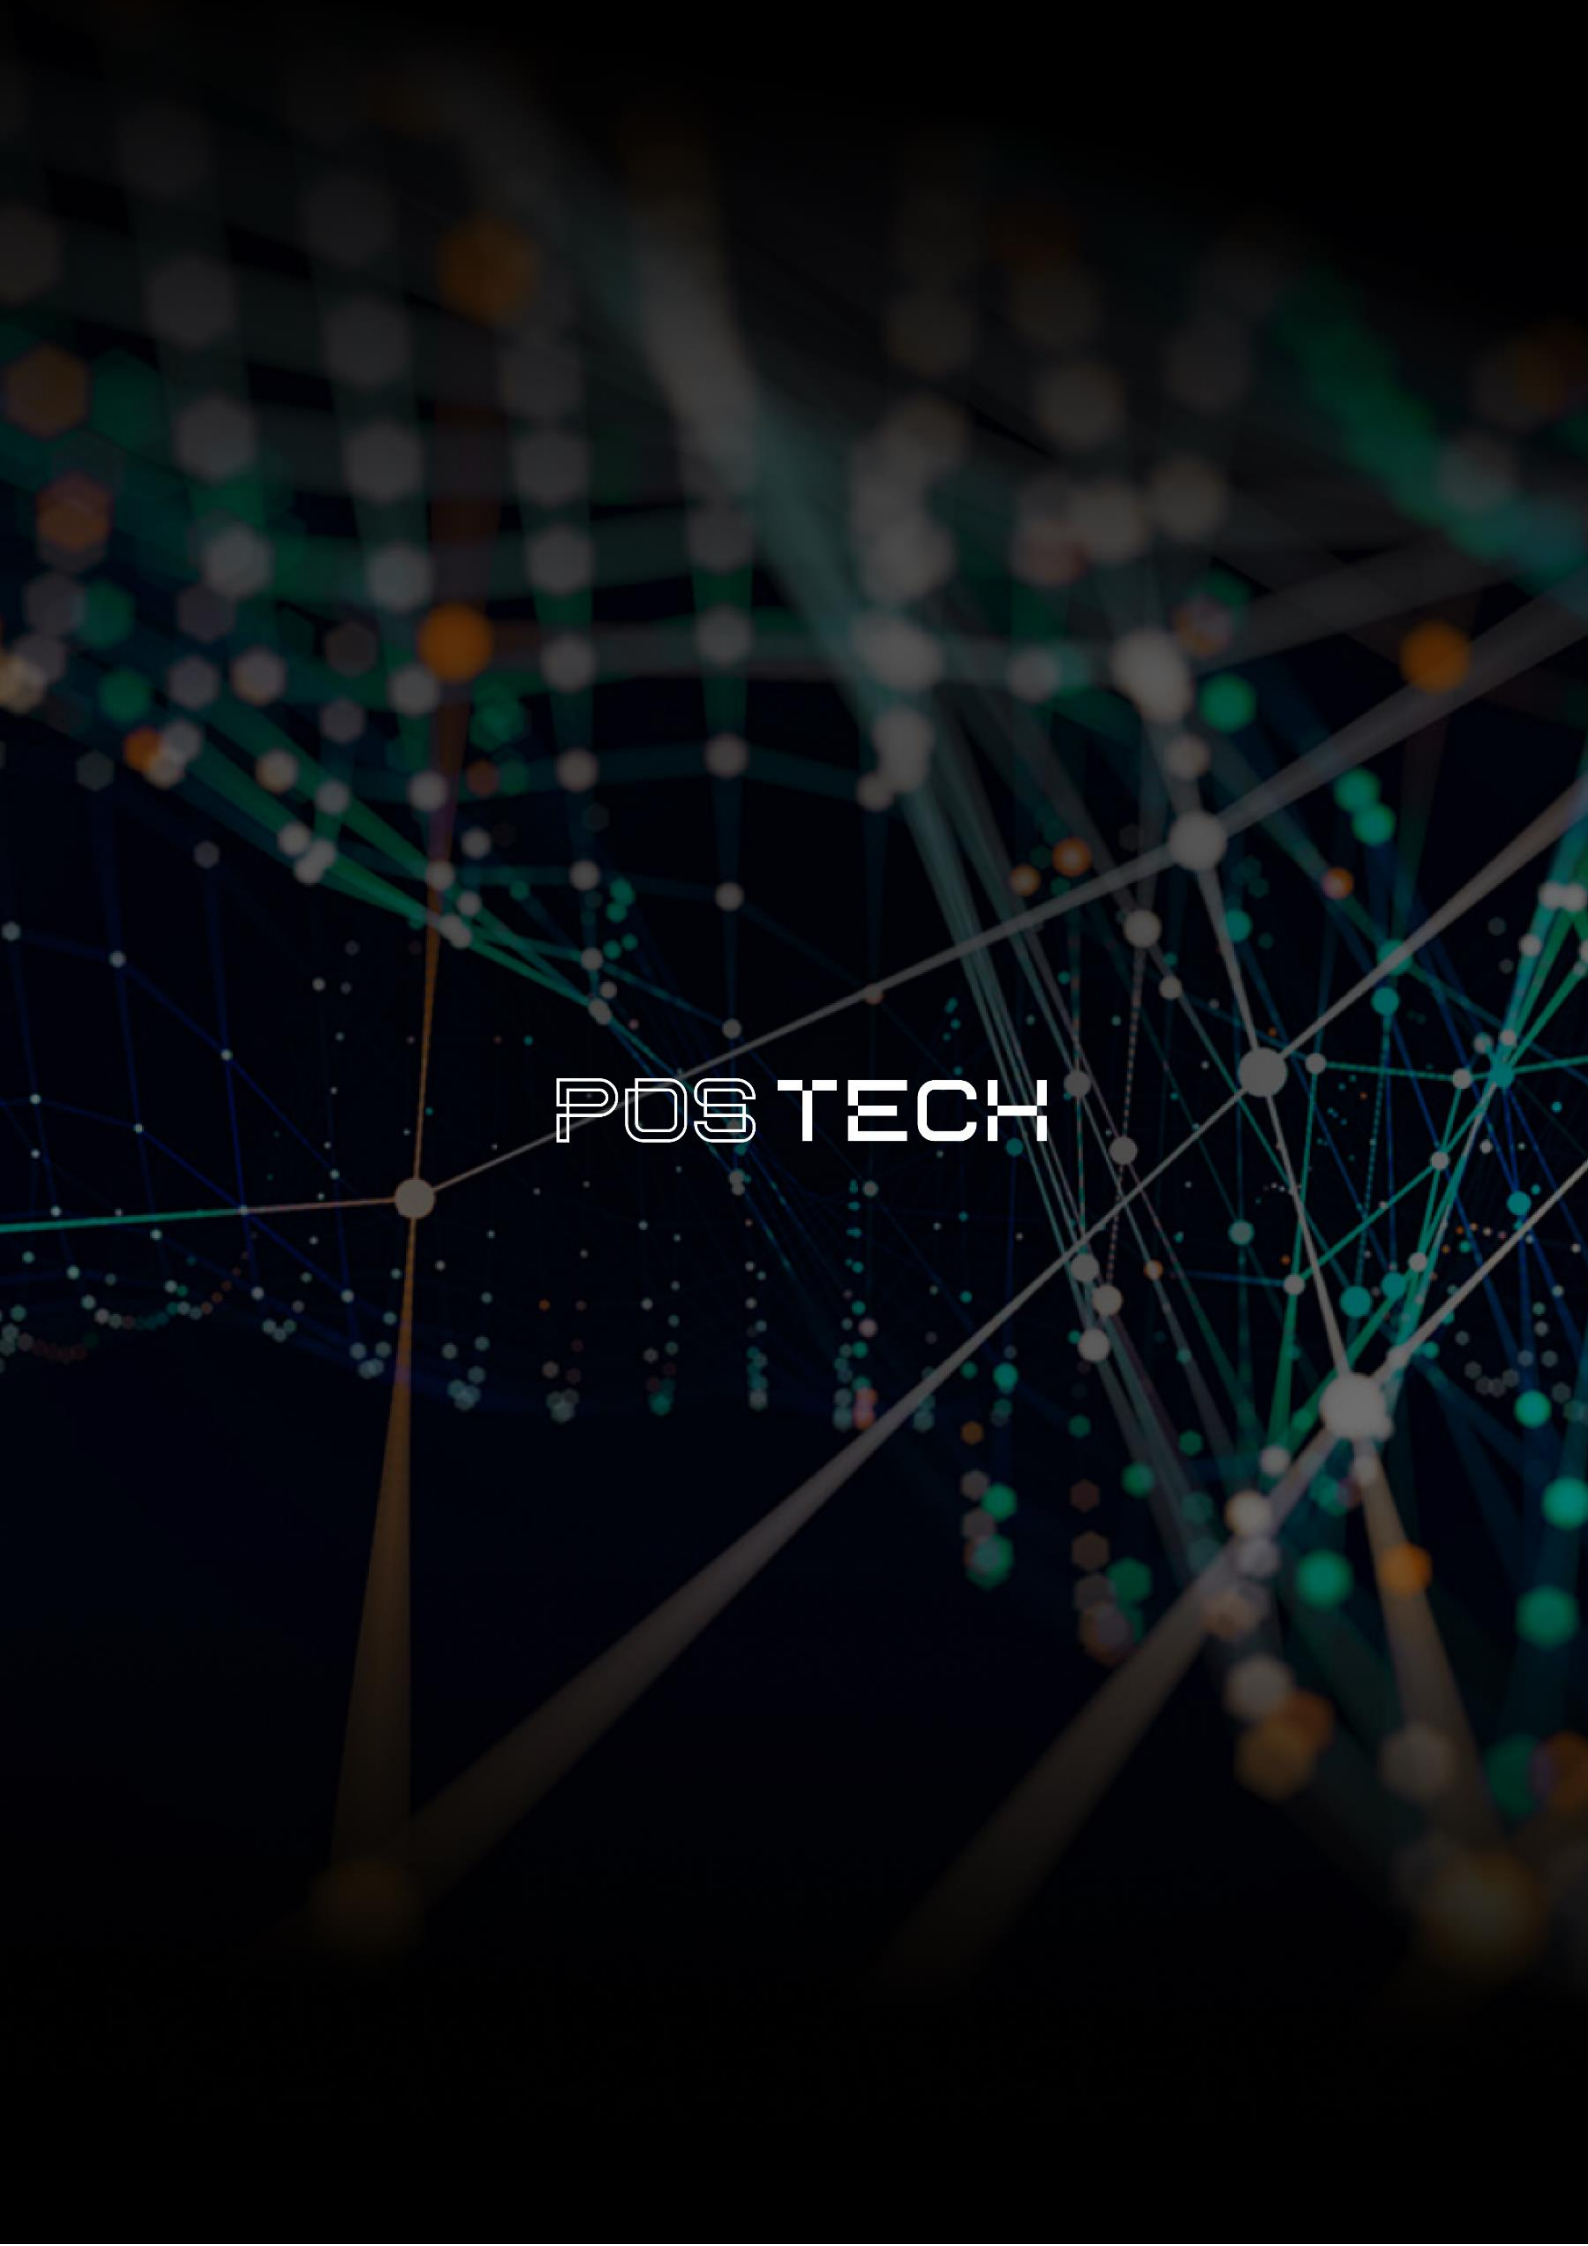
Recomendamos o uso de datasets públicos tabulares focados em risco, crédito ou precificação, onde a degradação econômica faz sentido prático.

Exemplos: German Credit Data (Kaggle/UCI), Home Credit Default Risk (Kaggle) ou Lending Club Loan Data. Qualquer dataset de classificação binária financeira com pelo menos 5.000 amostras é aceito.

Passo a Passo Resumido

- **[Etapa 1]** Treinar modelo base + Escrever regras de validação (Pandera/Great Expectations).
- **[Etapa 2]** Alterar os dados propositalmente para gerar Drift + Rodar testes estatísticos com Evidently.
- **[Etapa 3]** Consolidar logs e expor relatórios visuais/dashboards de monitoramento.
- **[Etapa 4]** Preencher documentação de LGPD no README + Gravar o Vídeo.

Caso tenha alguma dúvida, é só nos procurar no Discord!


POS TECH